Tugas 4: Praktikum & Praktikum Mandiri 4

Pandu Linggar Kumara - 0110221277,
Link GitHub - https://github.com/PanduLgg/M_Learning.git

[1] Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: pandulinggar1@gmail.com

Abstract. Algoritma Logistic Regression untuk memprediksi status stunting pada balita dengan menggunakan variabel umur, tinggi badan, berat badan, dan jenis kelamin. Proses diawali dengan tahap pra-pemrosesan data seperti pengubahan data kategorik menjadi numerik, standarisasi data, serta pembagian dataset menjadi data latih dan data uji. Model kemudian dilatih menggunakan scikit-learn dan dievaluasi menggunakan metrik akurasi, presisi, recall, F1-score, dan ROC-AUC. Berdasarkan hasil pengujian, model mencapai akurasi sekitar 90% dengan nilai ROC-AUC sebesar 0,97 yang menunjukkan performa yang sangat baik. Dari hasil analisis, tinggi badan berpengaruh paling besar dalam menurunkan kemungkinan stunting, sedangkan faktor umur dan jenis kelamin berpengaruh positif terhadap risiko stunting. Praktikum ini membantu mahasiswa memahami bagaimana Logistic Regression dapat digunakan untuk memecahkan masalah nyata di bidang kesehatan masyarakat.

1. Connecting Google Colab & Drive

1.1 Menghubungkan lingkungan Google Colab dengan akun Google Drive

Sel ini berfungsi untuk menghubungkan lingkungan Google Colab dengan akun Google Drive

```
from google.colab import drive
drive.mount('/content/drive')
df = pd.read_csv('/content/drive/MyDrive/praktikum_ml/praktikum03/data/stunting_wasting_dataset.csv')
df.drop_duplicates(inplace=True)
print("Shape of dataframe after dropping duplicates:", df.shape)
```

```
Mounted at /content/drive
Shape of dataframe after dropping duplicates: (92692, 6)
```

Gambar 1.1. Proses ini hanya perlu dilakukan satu kali per sesi.

1.2 Memanggil Data set dari Gdrive dan Membaca file .CSV menggunakan Pandas

Sel ini menggunakan library Pandas untuk membaca file data, yang diinginkan

```
from google.colab import drive
drive.mount('/content/drive')
df = pd.read_csv('/content/drive/MyDrive/praktikum_ml/praktikum03/data/stunting_wasting_dataset.csv')
df.head()
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
```

	Jenis Kelamin	Umur (bulan)	Tinggi Badan (cm)	Berat Badan (kg)	Stunting	Wasting
0	Laki-laki	19	91.6	13.3	Tall	Risk of Overweight
1	Laki-laki	20	77.7	8.5	Stunted	Underweight
2	Laki-laki	10	79.0	10.3	Normal	Risk of Overweight
3	Perempuan	2	50.3	8.3	Severely Stunted	Risk of Overweight
4	Perempuan	5	56.4	10.9	Severely Stunted	Risk of Overweight

Next steps: Generate code with df | New interactive sheet

Gambar 1.2. Proses ini hanya perlu dilakukan satu kali per sesi.

1.3 Mencari informasi data yang ada pada file

Sel ini menampilkan informasi yang ada di dalam file dari mulai tipe data nama kolom, dsb.

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 6 columns):
 #   Column             Non-Null Count   Dtype
---  ------             --------------   -----
 0   Jenis Kelamin      100000 non-null  object
 1   Umur (bulan)       100000 non-null  int64
 2   Tinggi Badan (cm)  100000 non-null  float64
 3   Berat Badan (kg)   100000 non-null  float64
 4   Stunting           100000 non-null  object
 5   Wasting            100000 non-null  object
dtypes: float64(2), int64(1), object(3)
memory usage: 4.6+ MB
```

Gambar 1.3. Mencari info data pada file

1.4 Cek data Null

Mengecek apakah terdapat data null

```
df.isnull().sum()
```

	0
Jenis Kelamin	0
Umur (bulan)	0
Tinggi Badan (cm)	0
Berat Badan (kg)	0
Stunting	0
Wasting	0

dtype: int64

Gambar 1.4. Mengecek apakah terdapat data null

1.5 Import Library dan Model
Mengimport beberapa library dan Model yang dibutuhkan

```
import numpy as np
import pandas as pd

from sklearn.model_selection import train_test_split
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder , StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (
    accuracy_score, precision_score, recall_score, f1_score, roc_auc_score, confusion_matrix,
    classification_report, RocCurveDisplay, ConfusionMatrixDisplay
)
```

Gambar 1.5. Mengimport Library

1.6 Cek Nilai Unik
Mengecek Data Unit dari mulai kolom Stunting dan Jenis Kelamin

```
df['Stunting'].unique()
```

```
array(['Tall', 'Stunted', 'Normal', 'Severely Stunted'], dtype=object)
```

```
df['Jenis Kelamin'].unique()
```

```
array(['Laki-laki', 'Perempuan'], dtype=object)
```

Gambar 1.6. Cek Nilai Unik

1.7 Mapping Kolom Kategorik ke Bentuk Numerik
Mengubah nilai teks menjadi bentuk numerik agar dapat diproses model

```
map_stunt = {'Stunted':1, 'Severely Stunted':1, 'Normal':0, 'Tall':0}
df['Stunting_bin'] = df['Stunting'].map(map_stunt).astype('Int64')

df['JK_bin'] = (df['Jenis Kelamin'] == 'Laki-laki').astype(int)

print("Distribusi Stunting_bin:\n", df['JK_bin'].value_counts())
print("\nDistribusi JK_bin:\n", df['JK_bin'].value_counts())
```

```
Distribusi Stunting_bin:
 JK_bin
1    50179
0    49821
Name: count, dtype: int64

Distribusi JK_bin:
 JK_bin
1    50179
0    49821
Name: count, dtype: int64
```

Gambar 1.7. Mapping Kolom Kategorik ke Bentuk Numerik

1.8 Korelasi Antar Variabel Numerik
menghitung korelasi Pearson antara setiap variabel numerik terhadap target Stunting_bin

```
corr_matrix = df.corr(numeric_only=True)
corr_matrix
```

	Umur (bulan)	Tinggi Badan (cm)	Berat Badan (kg)	Stunting_bin	JK_bin
Umur (bulan)	1.000000	0.875869	0.665389	0.038630	0.004046
Tinggi Badan (cm)	0.875869	1.000000	0.626005	-0.283855	0.073505
Berat Badan (kg)	0.665389	0.626005	1.000000	0.021090	0.045797
Stunting_bin	0.038630	-0.283855	0.021090	1.000000	-0.005981
JK_bin	0.004046	0.073505	0.045797	-0.005981	1.000000

Gambar 1.8. Korelasi Antar Variabel Numerik

1.9 Visualisasi Heatmap Korelasi
untuk melihat hubungan antar variabel numerik secara menyeluruh dalam dataset

```
import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(8,6))
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt='.2f', linewidths=0.5)
plt.title('HeatMap Korelasi Antar Variabel Numerik terhadap Stunting', fontsize=12)
plt.show()
```

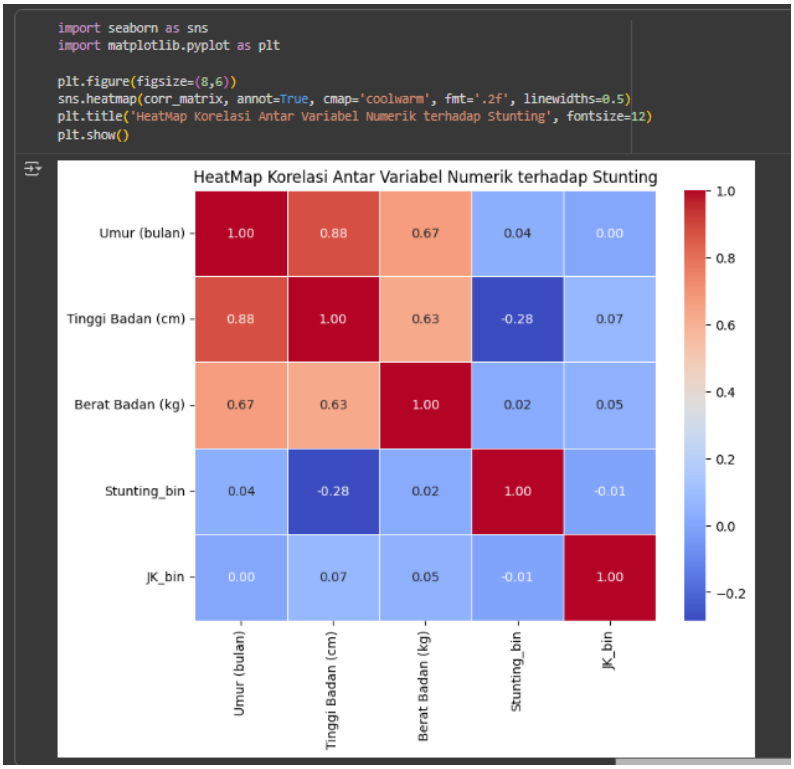

Gambar 1.9. Heatmap Korelasi

1.10 Menentukan Fitur dan Target

Mengubah dataset dibagi menjadi dua bagian utama, Variabel X berisi fitur atau variabel independen (Umur, Tinggi Badan, Berat Badan, dan Jenis Kelamin). Variabel y berisi variabel target yaitu Stunting_bin.

```
feature_num = ['Umur (bulan)', 'Tinggi Badan (cm)', 'Berat Badan (kg)']
feature_bin = ['JK_bin']

use_cols = feature_num + feature_bin + ['Stunting_bin']
df_model = df[use_cols].dropna().copy()

X = df_model[feature_num + feature_bin]
y = df_model['Stunting_bin']

print("X shape:", X.shape)
print("y shape:", y.shape)
```

```
X shape: (100000, 4)
y shape: (100000,)
```

Gambar 1.10. Fitur dan Target

1.11 Membagi Dataset menjadi Training dan Testing Set

80% data (80.000 baris) digunakan untuk melatih model (X_train, y_train),
20% data (20.000 baris) digunakan untuk menguji performa model (X_test, y_test)

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)

print("Data latih:", X_train.shape)
print("Data uji:", X_test.shape)
```

```
Data latih: (80000, 4)
Data uji: (20000, 4)
```

Gambar 1.11. Pembagian Dataset

1.12 Pembangunan Model Logistic Regression

Model berhasil dilatih menggunakan data training (80.000 baris)

```
preprocess = ColumnTransformer([
    ('num', StandardScaler(), feature_num),
    ('bin', 'passthrough', feature_bin)
], remainder='drop'
)

model = LogisticRegression(
    max_iter=1000,
    solver='lbfgs',
    class_weight='balanced',
    random_state=42
)

clf = Pipeline([
    ('preprocess', preprocess),
    ('model', model)
])

#latih Model
clf.fit(X_train, y_train)
print("Model Regression Berhasil Dilatih")
```

```
Model Regression Berhasil Dilatih
```

Gambar 1.12. Training Model Logistic Regression

1.13 Prediksi Model dan Evaluasi Model

menghasilkan label klasifikasi 0 (tidak stunting) atau 1 (stunting) dan memberikan probabilitas peluang stunting.

```
y_pred = clf.predict(X_test)
y_prob = clf.predict_proba(X_test)[:, 1]

# Hitung Numerik
print(f"Akurasi : {accuracy_score(y_test, y_pred):.4f}")
print(f"Presisi : {precision_score(y_test, y_pred, zero_division=0):.4f}")
print(f"Recall  : {recall_score(y_test, y_pred, zero_division=0):.4f}")
print(f"F1 Score: {f1_score(y_test, y_pred, zero_division=0):.4f}")
print(f"ROC AUC : {roc_auc_score(y_test, y_prob):.4f}")
```

```
Akurasi : 0.9055
Presisi : 0.7152
Recall  : 0.9472
F1 Score: 0.8150
ROC AUC : 0.9656
```

Gambar 1.13. Prediksi Model dan Evaluasi Model

1.14 Visualisasi Hasil Evaluasi

Setelah model Logistic Regression dilatih dan diuji menggunakan data uji sebanyak 20.000 baris, dilakukan evaluasi performa model melalui dua visual utama, yaitu ROC Curve dan Confusion Matrix

```
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

ConfusionMatrixDisplay(confusion_matrix(y_test, y_pred), display_labels=['Normal', 'Stunting']).plot(values_format='d', ax=axes[0])
axes[0].set_title("Confusion Matrix")

RocCurveDisplay.from_estimator(clf, X_test, y_test, ax=axes[1])
axes[1].set_title("ROC Curve Logistic Regression")

plt.tight_layout()
plt.show()
```

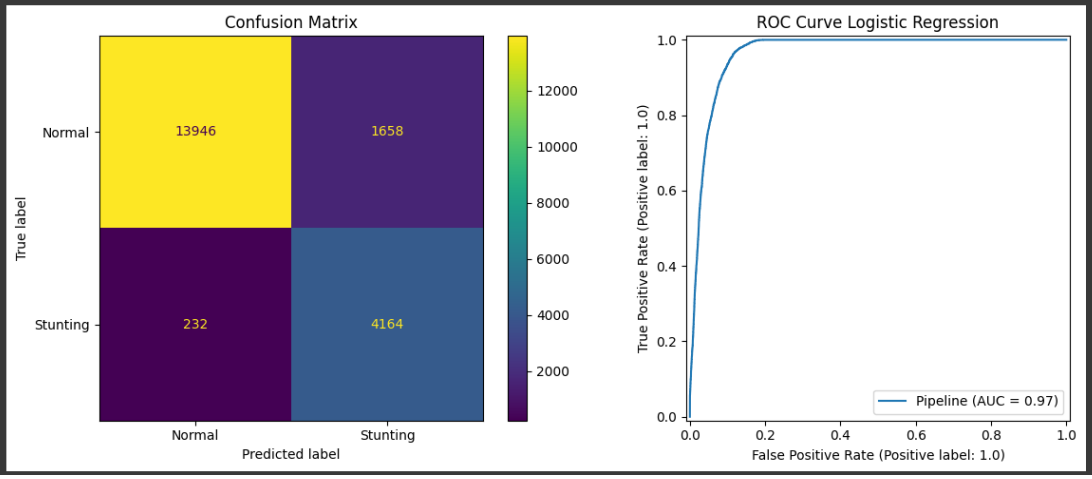

Gambar 1.14. Visualisasi Hasil Evaluasi Model

1.15 Classification Report
mengevaluasi performa model klasifikasi (seperti Logistic Regression)

```
from sklearn.metrics import classification_report

print(classification_report(y_test, y_pred, target_names= ['Tidak Stunting (0)', 'Stunting (1)']))
```

```
                    precision    recall  f1-score   support

Tidak Stunting (0)       0.98      0.89      0.94     15604
     Stunting (1)        0.72      0.95      0.82      4396

          accuracy                           0.91     20000
         macro avg       0.85      0.92      0.88     20000
      weighted avg       0.92      0.91      0.91     20000
```

Gambar 1.15. Gambaran keseimbangan performa model antara mendeteksi data positif (Stunting) dan negatif (Tidak Stunting)

1.16 Hasil Validasi
Langkah ini berfungsi untuk memastikan hasil model benar-benar konsisten dan tidak kebetulan bagus hanya di satu pembagian data.

```
from sklearn.model_selection import cross_val_score

scores = cross_val_score(clf, X, y, cv=5)

print("Skor tiap Fold:", scores)
print("Rata-rata Akurasi:", np.mean(scores))
print("Standart Deviasi:", np.std(scores))
```

```
Skor tiap Fold: [0.9062  0.9013  0.9052  0.89905 0.9002 ]
Rata-rata Akurasi: 0.9023899999999999
Standart Deviasi: 0.0028125433329995106
```

Gambar 1.16. Model Logistic Regression menunjukkan performa yang stabil dan dapat diandalkan di seluruh data

1.17 Interpretasi Model Logistic Regression
Langkah ini berfungsi untuk memastikan hasil model benar-benar konsisten dan tidak kebetulan bagus hanya di satu pembagian data.

```
feat_names = feature_num + feature_bin
coefs = clf.named_steps['model'].coef_[0]
odds = np.exp(coefs)

coef_df = pd.DataFrame({
    'Fitur': feat_names,
    'Koefisien (log-odds)': coefs,
    'Odds Ratio (e^coef)': odds
}).sort_values('Odds Ratio (e^coef)', ascending=False)

display(coef_df)
```

	Fitur	Koefisien (log-odds)	Odds Ratio (e^coef)
0	Umur (bulan)	8.525912	5043.782458
3	JK_bin	1.675944	5.343839
2	Berat Badan (kg)	0.661090	1.936903
1	Tinggi Badan (cm)	-10.535980	0.000027

Gambar 1.17. Mengetahui seberapa besar pengaruh setiap fitur (variabel input) terhadap peluang terjadinya stunting

1.18 (Contoh Kasus)

Untuk mengetahui apakah model dapat melakukan prediksi dengan benar dan logis berdasarkan karakteristik anak.

```
data_baru = pd.DataFrame({
    'Umur (bulan)' : [24,10],
    'Tinggi Badan (cm)': [79.0, 72.5],
    'Berat Badan (kg)' : [9.2, 7.8],
    'JK_bin' : [1,0]
})

pred = clf.predict(data_baru)
prob = clf.predict_proba(data_baru)[:,1]

hasil = data_baru.copy()
hasil['Prob_Stuntung'] = prob
hasil['Pred (0=Tidak Stunting, 1=Stunting)'] = pred

display(hasil)
```

	Umur (bulan)	Tinggi Badan (cm)	Berat Badan (kg)	JK_bin	Prob_Stuntung	Pred (0=Tidak Stunting, 1=Stunting)
0	24	79.0	9.2	1	0.998208	1.0
1	10	72.5	7.8	0	0.002094	0.0

Gambar 1.17. Mengetahui seberapa besar pengaruh setiap fitur (variabel input) terhadap peluang terjadinya stunting

2. LOGISTIC REGRESSION (MANDIRI)

2.1 Menarik Data

Membaca data calonpembelimobil.csv

```
from google.colab import drive
drive.mount('/content/drive')
df = pd.read_csv('/content/drive/MyDrive/praktikum_ml/praktikum04/data/calonpembelimobil.csv')
df.drop_duplicates(inplace=True)
print("Shape of dataframe after dropping duplicates:", df.shape)
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
Shape of dataframe after dropping duplicates: (1000, 7)
```

Gambar 2.1. Menarik Data

2.2 Membaca Isi Data dan Data Teratas

Melihat Informasi yang ada didalam Data calonpembelimobil.csv

```
print("5 Data Teratas:")
print(df.head())


print("Informasi Dataset:")
df.info()
```

```
5 Data Teratas:
   ID  Usia  Status  Kelamin  Memiliki_Mobil  Penghasilan  Beli_Mobil
0   1    32       1        0               0          240           1
1   2    49       2        1               1          100           0
2   3    52       1        0               2          250           1
3   4    26       2        1               1          130           0
4   5    45       3        0               2          237           1
Informasi Dataset:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 7 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   ID              1000 non-null   int64
 1   Usia            1000 non-null   int64
 2   Status          1000 non-null   int64
 3   Kelamin         1000 non-null   int64
 4   Memiliki_Mobil  1000 non-null   int64
 5   Penghasilan     1000 non-null   int64
 6   Beli_Mobil      1000 non-null   int64
dtypes: int64(7)
memory usage: 54.8 KB
```

Gambar 2.2. Menampilkan Data Info

2.3 Mencari Nilai Unik

Mencari Nilai Unik dalam setiap kolom

```
print("Nilai Unik Setiap Kolom:")
for col in df.columns:
  print(f"\nKolom: {col}")
  print(df[col].unique())
```

```
Jumlah Missing Values:
ID              0
Usia            0
Status          0
Kelamin         0
Memiliki_Mobil  0
Penghasilan     0
Beli_Mobil      0
dtype: int64
Nilai Unik Setiap Kolom:

Kolom: ID
[  1   2   3   4   5   6   7   8   9  10  11  12  13  14
  15  16  17  18  19  20  21  22  23  24  25  26  27  28
  29  30  31  32  33  34  35  36  37  38  39  40  41  42
  43  44  45  46  47  48  49  50  51  52  53  54  55  56
  57  58  59  60  61  62  63  64  65  66  67  68  69  70
  71  72  73  74  75  76  77  78  79  80  81  82  83  84
  85  86  87  88  89  90  91  92  93  94  95  96  97  98
  99 100 101 102 103 104 105 106 107 108 109 110 111 112
 113 114 115 116 117 118 119 120 121 122 123 124 125 126
 127 128 129 130 131 132 133 134 135 136 137 138 139 140
 141 142 143 144 145 146 147 148 149 150 151 152 153 154
 155 156 157 158 159 160 161 162 163 164 165 166 167 168
 169 170 171 172 173 174 175 176 177 178 179 180 181 182
 183 184 185 186 187 188 189 190 191 192 193 194 195 196
 197 198 199 200 201 202 203 204 205 206 207 208 209 210
 211 212 213 214 215 216 217 218 219 220 221 222 223 224
 225 226 227 228 229 230 231 232 233 234 235 236 237 238
 239 240 241 242 243 244 245 246 247 248 249 250 251 252
 253 254 255 256 257 258 259 260 261 262 263 264 265 266
 267 268 269 270 271 272 273 274 275 276 277 278 279 280
 281 282 283 284 285 286 287 288 289 290 291 292 293 294
 295 296 297 298 299 300 301 302 303 304 305 306 307 308
 309 310 311 312 313 314 315 316 317 318 319 320 321 322
 323 324 325 326 327 328 329 330 331 332 333 334 335 336
```

Gambar 2.3. Tampilan Nilai kolom

2.4 Memisahkan Fitur dan Target

Tahapan ini memisahkan Nilai Fitur dan Target

```
X = df[['Usia', 'Status', 'Kelamin', 'Memiliki_Mobil', 'Penghasilan']]
y = df['Beli_Mobil']
```

Gambar 2.4. Memisahkan FItur dan Target

2.5 Membagi Data Latih dan Uji
Melatih dan menguji 2 data

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"\nJumlah data latih: {len(X_train)}")
print(f"Jumlah data uji: {len(X_test)}")
```

```
Jumlah data latih: 800
Jumlah data uji: 200
```

Gambar 2.5. Data Latih dan Uji

2.6 Buat dan latih model Logistic Regression
Melatih Model Regression

```
model = LogisticRegression()
model.fit(X_train_scaled, y_train)
```

```
LogisticRegression()
```

Gambar 2.6. Latih Model

2.7 Evaluasi Model
Evaluasi Model Regression

```
y_pred = model.predict(X_test_scaled)


print("Akurasi Model:", accuracy_score(y_test, y_pred))
print("Precision:", precision_score(y_test, y_pred))
print("Recall:", recall_score(y_test, y_pred))
print("F1 Score:", f1_score(y_test, y_pred))
print("ROC AUC:", roc_auc_score(y_test, y_pred))


print("Laporan Klasifikasi:\n", classification_report(y_test, y_pred))
```

```
Akurasi Model: 0.925
Precision: 0.935251798561151
Recall: 0.9558823529411765
F1 Score: 0.9454545454545454
ROC AUC: 0.9076286764705883
Laporan Klasifikasi:
              precision    recall  f1-score   support

           0       0.90      0.86      0.88        64
           1       0.94      0.96      0.95       136

    accuracy                           0.93       200
   macro avg       0.92      0.91      0.91       200
weighted avg       0.92      0.93      0.92       200
```

Gambar 2.7. Evaluasi Model

2.8 Visualisasi Data
Visualisasi Data hasil

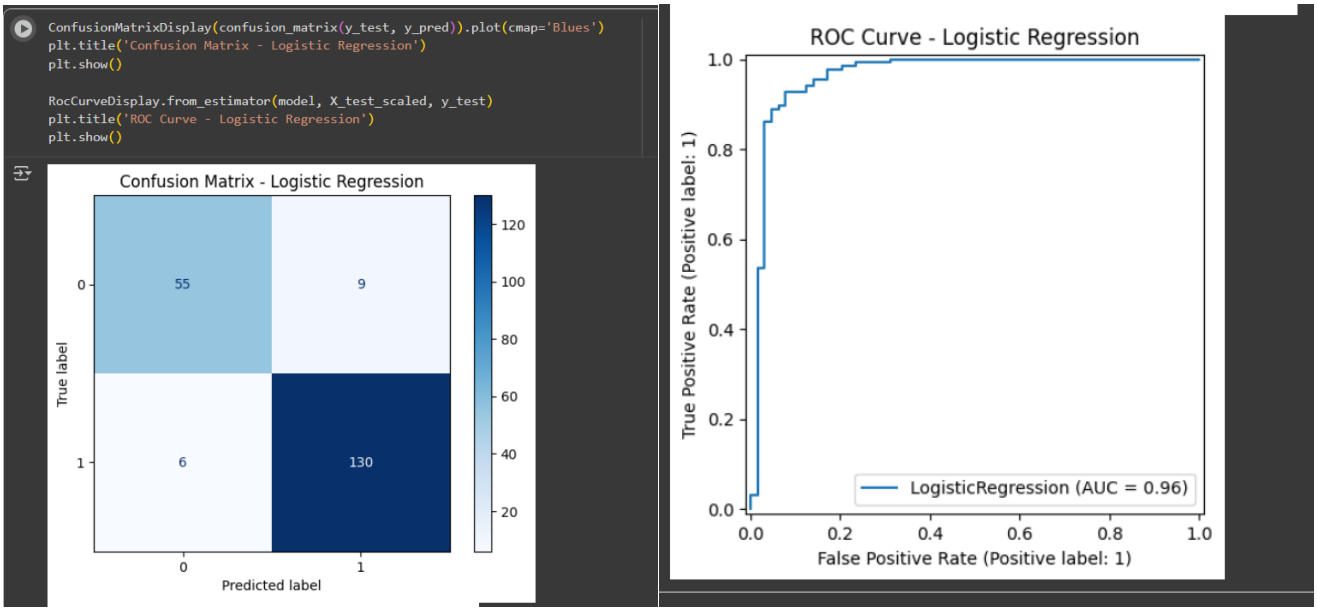

Gambar 2.8. Visualsisasi Model

2.9 Buat Data Baru
Data Baru untuk menguji apakah model dapat memprediksi sesuai dengan data serupa

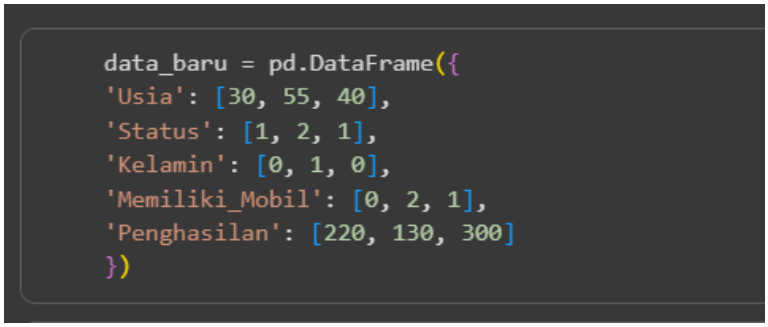

Gambar 2.9. Data Baru

2.10 Buat Data Baru
Prediksi Data Baru

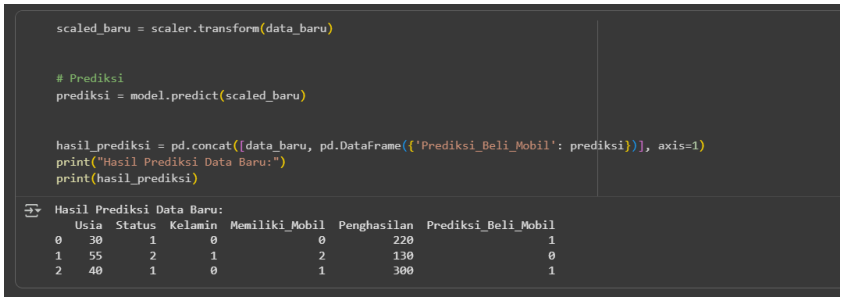

Gambar 2.10. Prediksi Data Baru

KESIMPULAN

Berdasarkan hasil percobaan yang telah dilakukan menggunakan metode **Logistic Regression**, model mampu mengklasifikasikan calon pembeli mobil dengan cukup baik. Nilai akurasi yang diperoleh menunjukkan bahwa model memiliki performa yang baik dalam memprediksi keputusan pembelian mobil berdasarkan variabel seperti umur, pendapatan, status, dan pekerjaan.

Dengan demikian, Logistic Regression dapat digunakan sebagai model prediksi awal untuk menentukan kemungkinan seseorang membeli mobil.

Referensi:

Munir, S., Seminar, K. B., Sudradjat, Sukoco, H., & Buono, A. (2022). The Use of Random Forest Regression for Estimating Leaf Nitrogen Content of Oil Palm Based on Sentinel 1-A Imagery. *Information*, *14*(1), 10. https://doi.org/10.3390/info14010010

Seminar, K. B., Imantho, H., Sudradjat, Yahya, S., Munir, S., Kaliana, I., Mei Haryadi, F., Noor Baroroh, A., Supriyanto, Handoyo, G. C., Kurnia Wijayanto, A., Ijang Wahyudin, C., Liyantono, Budiman, R., Bakir Pasaman, A., Rusiawan, D., & Sulastri. (2024). PreciPalm: An Intelligent System for Calculating Macronutrient Status and Fertilizer Recommendations for Oil Palm on Mineral Soils Based on a Precision Agriculture Approach. *Scientific World Journal*, *2024*(1). https://doi.org/10.1155/2024/1788726