

Tugas 9: Praktikum & Praktikum Mandiri 9

Pandu Linggar Kumara - 0110221277,
Link GitHub - https://github.com/PanduLgg/M_Learning.git

¹ Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: pandulinggar1@gmail.com

Abstract. Eksperimen ini bertujuan untuk menerapkan dan mengevaluasi kinerja algoritma klasifikasi Gaussian Naive Bayes (GNB) pada dua kasus klasifikasi biner yang berbeda. Model GNB pertama diterapkan pada data kelangsungan hidup penumpang Titanic (praktikum09.ipynb), di mana model dilaporkan mencapai akurasi sempurna 100% pada pengujian dan 5-Fold Cross-Validation. Hasil ini dicurigai tidak realistis karena potensi data leakage atau overfitting yang ekstrem dalam set data praktikum asli. Untuk validasi pada data dunia nyata, model GNB kemudian diterapkan pada Dataset Kanker Payudara (data.csv). Setelah pra-pemrosesan data dan feature scaling, model diuji menggunakan 5-Fold Cross-Validation yang menghasilkan Akurasi Rata-rata sebesar 93.85% dengan standar deviasi yang sangat rendah (0.0146). Hasil ini menunjukkan bahwa algoritma GNB adalah metode klasifikasi yang efektif dan stabil untuk data biomedis yang kompleks, serta memberikan kinerja yang kuat tanpa mengorbankan kemampuan generalisasi.

1. PRAKTIKUM 09

1.1 Import Library dan Model

Sel ini berfungsi untuk Mengimport Library dan Model yang dibutuhkan

```
PRAKTIKUM 09

[159]
✓ Os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
from sklearn.preprocessing import StandardScaler
from sklearn.naive_bayes import GaussianNB
```

Gambar 1.1. Proses ini hanya perlu dilakukan satu kali per sesi.

1.2 Memanggil Data set dari Gdrive dan Membaca file .CSV menggunakan Pandas

Sel ini menggunakan library Pandas untuk membaca file data, yang diinginkan


```
from google.colab import drive
drive.mount('/content/drive')
titanic_data = pd.read_csv('/content/drive/MyDrive/praktikum_ml/praktikum09/data/tested.csv')

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
```

Gambar 1.2. Proses ini hanya perlu dilakukan satu kali per sesi.

1.3 Mencari informasi data yang ada pada file

Sel ini menampilkan informasi yang ada di dalam file dari head sampai bawah(tail) titanic_data



The screenshot shows a Jupyter Notebook interface. At the top, the command `titanic_data.head()` is entered. Below it, a table displays the first five rows of the dataset. The columns are PassengerId, Survived, Pclass, Name, Sex, Age, SibSp, Parch, Ticket, Fare, Cabin, and Embarked. Below the table, there are two buttons: "Generate code with titanic_data" and "New interactive sheet". Below these buttons, the command `titanic_data.tail()` is entered. Below it, another table displays the last five rows of the dataset, with the same columns as the first table.

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	892	0	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292	NaN	Q
1	893	1	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000	NaN	S
2	894	0	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875	NaN	Q
3	895	0	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625	NaN	S
4	896	1	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875	NaN	S


Next steps: [Generate code with titanic_data](#) [New interactive sheet](#)

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
413	1305	0	3	Spector, Mr. Woolf	male	NaN	0	0	A.5. 3236	8.0500	NaN	S
414	1306	1	1	Oliva y Ocana, Dona. Fermina	female	39.0	0	0	PC 17758	108.9000	C105	C
415	1307	0	3	Saether, Mr. Simon Sivertsen	male	38.5	0	0	SOTON/O.Q. 3101262	7.2500	NaN	S
416	1308	0	3	Ware, Mr. Frederick	male	NaN	0	0	359309	8.0500	NaN	S
417	1309	0	3	Peter, Master. Michael J	male	NaN	1	1	2668	22.3583	NaN	C

Gambar 1.3. Mencari info data pada file dari awal sampai akhir

1.4 Mensummary kolom null

Summary kolom nul pada titanic_data



The screenshot shows a Jupyter Notebook interface. The command `titanic_data.isnull().sum()` is entered. Below it, a table displays the summary of null values for each column. The columns are PassengerId, Survived, Pclass, Name, Sex, Age, SibSp, Parch, Ticket, Fare, Cabin, and Embarked. The values are: PassengerId: 0, Survived: 0, Pclass: 0, Name: 0, Sex: 0, Age: 86, SibSp: 0, Parch: 0, Ticket: 0, Fare: 1, Cabin: 327, Embarked: 0. The dtype is int64.


	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	0	0	0	0	0	86	0	0	0	1	327	0

dtype: int64

Gambar 1.4. Mencari kolom Null

1.5 Drop Data

Drop Kolom yang bukan data utama yang akan digunakan




```
titanic_data = titanic_data.drop(columns=['PassengerId','Cabin','Name','Ticket'], axis=1)
```

Gambar 1.5. Drop data optional

1.6 Visualisasi Boxplot

Visualisasikan Kolom Age dan Fare menggunakan Boxplot agar mengecek outlier



Gambar 1.6. Outlier Age dan Fare

1.7 Mengisi Missing Value

Mengisi missing values pada kolom Age (usia) dengan nilai median dari kolom tersebut. Median lebih tahan terhadap outliers dibandingkan mean. o Mengisi missing values pada kolom Fare (tarif) dengan nilai median dari kolom tersebut.

```
titanic_data['Age'].fillna(titanic_data['Age'].median(), inplace=True)
titanic_data['Fare'].fillna(titanic_data['Fare'].median(), inplace=True)

/tmp/ipython-input-423417795.py:1: FutureWarning: A value is trying to be set on a copy of a DataFrame or Series through chained assignment using an inplace method.
The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method(col= value, inplace=True)' or 'df[col] = df[col].method(value)' instead, to perform the operation inplace on the original object.

titanic_data['Age'].fillna(titanic_data['Age'].median(), inplace=True)
/tmp/ipython-input-423417795.py:2: FutureWarning: A value is trying to be set on a copy of a DataFrame or Series through chained assignment using an inplace method.
The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method(col= value, inplace=True)' or 'df[col] = df[col].method(value)' instead, to perform the operation inplace on the original object.

titanic_data['Fare'].fillna(titanic_data['Fare'].median(), inplace=True)
```

Gambar 1.7. Isi Missing Value

1.8 Double Check Data Null

Pengecekan ulang menunjukkan semua missing values telah diatasi, dan jumlah kolom tersisa adalah 8

```
titanic_data.isnull().sum()
```

```
0
Survived 0
Pclass 0
Sex 0
Age 0
SibSp 0
Parch 0
Fare 0
Embarked 0

dtype: int64
```

Gambar 1.8. Cek kembali data Null setelah pengisian Age dan Fare

1.9 Data Analysis

Memberikan ringkasan statistik (rata-rata, standar deviasi, min/max, kuartil) untuk kolom numerik.

```
titanic_data.describe()
```

	Survived	Pclass	Age	SibSp	Parch	Fare
count	418.000000	418.000000	418.000000	418.000000	418.000000	418.000000
mean	0.363636	2.265550	29.599282	0.447368	0.392344	35.576535
std	0.481622	0.841838	12.703770	0.896760	0.981429	55.850103
min	0.000000	1.000000	0.170000	0.000000	0.000000	0.000000
25%	0.000000	1.000000	23.000000	0.000000	0.000000	7.895800
50%	0.000000	3.000000	27.000000	0.000000	0.000000	14.454200
75%	1.000000	3.000000	35.750000	1.000000	0.000000	31.471875
max	1.000000	3.000000	76.000000	8.000000	9.000000	512.329200

Gambar 1.9. Deskripsi Data untuk Analisis

1.10 Menghitung Value

Menghitung value setiap kolom (survived, sex, class)

```
titanic_data['Survived'].value_counts()
```

Survived	count
0	266
1	152

dtype: int64

```
titanic_data['Sex'].value_counts()
```

Sex	count
male	266
female	152

dtype: int64

```
titanic_data['Pclass'].value_counts()
```

Pclass	count
3	218
1	107
2	93

dtype: int64

Gambar 1.10. Value Counts

1.11 Visualisasi Bar Chart

Menunjukkan korelasi visual antara fitur (Sex, Pclass, Embarked) dengan target Survived. Terlihat jelas bahwa perempuan (Sex=female) dan penumpang Kelas 1 (Pclass=1) memiliki tingkat kelangsungan hidup yang lebih tinggi.



Gambar 1.11. Visualisasi Data

1.12 Encoding Data

Model Encoding Kategorikal: Fitur Sex dan Embarked diubah menjadi nilai numerik agar dapat diproses oleh model: Sex: male -> 0, female -> 1, dan Embarked (Pelabuhan Keberangkatan): S -> 0, C -> 1, Q -> 2

```
replacements = {
    'Sex':{'male':0, 'female':1},
    'Embarked':{'S':0, 'C':1, 'Q':2}
}

# Impute missing Embarked values with the mode before encoding
titanic_data['Embarked'].fillna(titanic_data['Embarked'].mode()[0], inplace=True)

titanic_data.replace(replacements, inplace=True)
```

/tmp/ipython-input-3411072000.py:7: FutureWarning: A value is trying to be set on a copy. The behavior will change in pandas 3.0. This inplace method will never work because the

For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col

Gambar 1.12. Encoding Data Sex dan Embarked

1.13 Separating, Splitting, and Train Test Data

`X = titanic_data.drop(columns=['Survived'])` Fitur (X) adalah semua kolom kecuali target Survived.

`Y = titanic_data['Survived']` Target (Y) adalah kolom yang ingin diprediksi.

Kemudian `train_test_split(...)` Membagi data menjadi 80% untuk training (334 data) dan 20% untuk testing (84 data). Argumen `stratify=Y` memastikan proporsi kelas Survived seimbang di kedua set.

```
X = titanic_data.drop(columns=['Survived'])
Y = titanic_data['Survived']

X.head()

  Pclass  Sex  Age  SibSp  Parch  Fare  Embarked
0      3    0  34.5     0     0   7.8292         2
1      3    1  47.0     1     0   7.0000         0
2      2    0  62.0     0     0   9.6875         2
3      3    0  27.0     0     0   8.6625         0
4      3    1  22.0     1     1  12.2875         0

Next steps: Generate code with X New interactive sheet

Y.head()

  Survived
0        0
1        1
2        0
3        0
4        1

dtype: int64

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2, stratify=Y, random_state=42)
```

Gambar 1.13. Separate, Split, dan Train Test Data

1.14 Scaling Data

- `scaler = StandardScaler()` Objek `StandardScaler` dibuat untuk menstandarisasi fitur (membuat mean = 0 dan standard deviation = 1).
- `scaler.fit_transform(X_train)` Melatih scaler pada data training dan menerapkannya. Ini sangat penting untuk Naive Bayes, terutama GaussianNB, karena sensitif terhadap skala fitur.
- `scaler.transform(X_test)` Menerapkan scaler yang sudah dilatih ke data testing.

```
print(X.shape, X_train.shape, X_test.shape)


(418, 7) (334, 7) (84, 7)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Gambar 1.14. Scaling Data

1.15 Menggunakan Algoritma Naïve Baiyes

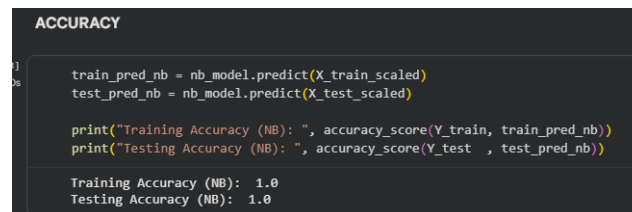
Model Gaussian Naive Bayes dibangun dan dilatih menggunakan data yang sudah distandarisasi



Gambar 1.15. Model Naïve Baiyes

1.16 Accuracy Score & Evaluation

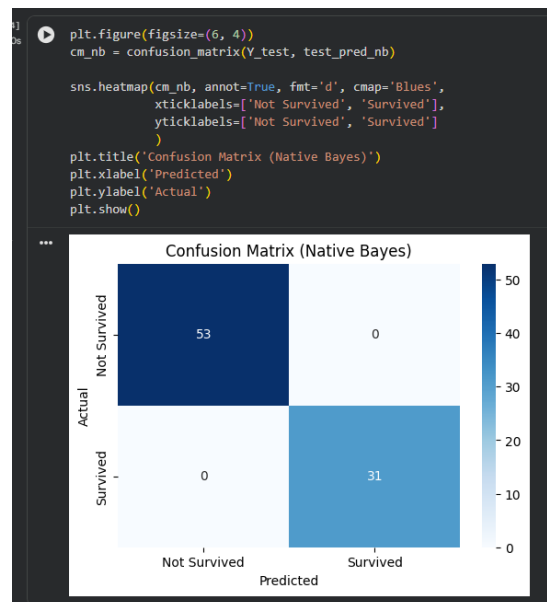
Menunjukkan Akurasi Model setelah dilatih dan dites



Gambar 1.16. Accuracy Score

1.17 Visualisasi Confusion Matrix

Confusion Matrix memvisualisasikan hasil prediksi dibandingkan dengan nilai sebenarnya. Menghitung Confusion Matrix berdasarkan hasil prediksi pada data uji.



Gambar 1.17. Confusion Matrix

1.18 Classification Report dan Cross Validation

Class Report: Menampilkan metrik seperti Precision, Recall, dan F1-Score untuk setiap kelas. Hasil: Semua metrik bernilai 1.00, menegaskan performa yang sempurna pada data uji, dan K-Fold Cross-Validation dilakukan untuk menguji model pada 5 subset data yang berbeda, memberikan metode evaluasi yang lebih andal.

```
print("\nClassification Report (NB):")
print(classification_report(Y_test, test_pred_nb))

Classification Report (NB):
              precision    recall  f1-score   support

     0               1.00      1.00      1.00        53
     1               1.00      1.00      1.00        31

 accuracy               1.00
 macro avg              1.00
 weighted avg           1.00
```

CROSS VALIDATION

```
from sklearn.model_selection import cross_val_score
cv_nb = cross_val_score(nb_model, X, Y, cv=5, scoring='accuracy')
print("\nNaive Bayes Cross Validation Accuracy (5-Fold):")
print("Scores:", cv_nb)
print("Mean Accuracy: ", cv_nb.mean())
print("Standart Deviation: ", cv_nb.std())

Naive Bayes Cross Validation Accuracy (5-Fold):
Scores: [1. 1. 1. 1. 1.]
Mean Accuracy: 1.0
Standart Deviation: 0.0
```

Gambar 1.18. Classification Report dan Cross Validation

2. PRAKTIKUM MANDIRI (MANDIRI)

2.1 Import Library

Import Model dan Library yang akan digunakan

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
from sklearn.preprocessing import StandardScaler
from sklearn.naive_bayes import GaussianNB
```

Gambar 2.1. Import Library dan Model

2.2 Menarik Dataset Wine Quality

Menarik data dari Kaggle yaitu "Cancer Dataset"

```
from google.colab import drive
drive.mount('/content/drive')
data = pd.read_csv('/content/drive/MyDrive/praktikum_ml/praktikum09/data/data.csv')

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
```

Gambar 2.2. Import Dataset

2.3 Cek dan membaca informasi data

Melihat Informasi Data Cancer Dataset

```
print("Data Awal (5 Baris Teratas):")
print(data.head())
print("\nInformasi Data:")
data.info()

***
compactness_worst  concavity_worst  concave points_worst  symmetry_worst \
0      0.6656      0.7119      0.2654      0.4601
1      0.1866      0.2416      0.1860      0.2750
2      0.4245      0.4504      0.2430      0.3613
3      0.8663      0.6869      0.2575      0.6638
4      0.2050      0.4000      0.1625      0.2364

fractal_dimension_worst  Unnamed: 32
0      0.11890      NaN
1      0.08902      NaN
2      0.08758      NaN
3      0.17300      NaN
4      0.07678      NaN

[5 rows x 33 columns]

Informasi Data:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 33 columns):
#   Column              Non-Null Count  Dtype
---  -
0   id                  569 non-null   int64
1   diagnosis           569 non-null   object
2   radius_mean         569 non-null   float64
3   texture_mean        569 non-null   float64
4   perimeter_mean      569 non-null   float64
5   area_mean           569 non-null   float64
6   smoothness_mean     569 non-null   float64
7   compactness_mean    569 non-null   float64
8   concavity_mean      569 non-null   float64
9   concave points_mean  569 non-null   float64
10  symmetry_mean       569 non-null   float64
11  fractal_dimension_mean  569 non-null   float64
12  radius_se           569 non-null   float64
13  texture_se          569 non-null   float64
```

Gambar 2.3. Tampilan Isi Data

2.4 Melihat Data Null

Cek Data Null


```
data.isnull().sum()
```

radius_mean	0
texture_mean	0
perimeter_mean	0
area_mean	0
smoothness_mean	0
compactness_mean	0
concavity_mean	0
concave points_mean	0
symmetry_mean	0
fractal_dimension_mean	0
radius_se	0
texture_se	0
perimeter_se	0
area_se	0
smoothness_se	0
compactness_se	0
concavity_se	0
concave points_se	0
symmetry_se	0
fractal_dimension_se	0
radius_worst	0

Gambar 2.4. Visualisasi Boxplot

2.5 Visualisasi Boxplot

Boxplot Diagnosis dengan seberapa buruk kondisinya



Gambar 2.5. Cek Data Null

2.6 Drop dan Encoding

Drop data dari column yang tidak relate, dan Encoding kolom diagnosis

```
data = data.drop(['id', 'Unnamed: 32'], axis=1)

data['diagnosis'] = data['diagnosis'].map({'B': 0, 'M': 1})
```

Gambar 2.6. 2 Drop dan Encoding Data

2.7 Visualisasi Data Diagnosis

Visualisasi Data kolom diagnosis setelah di encoding



Gambar 2.7. Visualisasi Data Diagnosis

2.8 Separating, Splitting, and Train Test Data

Memisahkan data X dan Y kemudian melihat jumlah value data yang akan dilatih dan diuji

```
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.3, random_state=42)

print(f"\nUkuran Data Latih (X_train): {X_train.shape}")
print(f"Ukuran Data Uji (X_test): {X_test.shape}")

ukuran Data Latih (X_train): (398, 30)
ukuran Data Uji (X_test): (171, 30)

scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Gambar 2.8. Separating, Splitting, and Train Test Data

2.9 Model Naïve Baiyes

Mengaktifkan Model Algoritma Naïve Baiyes dan melihat akurasi Data yang telah diuji yaitu sebesar 0.93, atau 93% tingkat akurasi

```
nb_model = GaussianNB()
nb_model.fit(X_train_scaled, Y_train)

***
GaussianNB
GaussianNB()

Y_pred = nb_model.predict(X_test_scaled)
accuracy = accuracy_score(Y_test, Y_pred)
print(f"AKURASI Model Gaussian Naive Bayes pada Data Uji: {accuracy:.4f}")

AKURASI Model Gaussian Naive Bayes pada Data Uji: 0.9357
```

Gambar 2.9. Hasil Prediksi dan Evaluasi Model

2.10 Visualisasi Confusion Matrix

Menampilkan confusion matrix dalam bentuk grafik visual



Gambar 2.10. Visualisasi Confusion Matrix

2.11 Classsification Report

Menampilkan metrik seperti Precision, Recall, dan F1-Score untuk setiap kelas. Hasil: Semua metrik bernilai 1.00, menegaskan performa yang sempurna pada data uji.

```
class_report = classification_report(y_test, y_pred)
print("\nClassification Report:")
print(class_report)
```

Classification Report:				
	precision	recall	f1-score	support
0	0.94	0.95	0.95	108
1	0.92	0.90	0.91	63
accuracy			0.94	171
macro avg	0.93	0.93	0.93	171
weighted avg	0.94	0.94	0.94	171

Gambar 2.11. Hasil Classification

2.12 Cross Validation

K-Fold Cross-Validation dilakukan untuk menguji model pada 5 subset data yang berbeda, memberikan metode evaluasi yang lebih andal.

```
CROSS VALIDATION

from sklearn.model_selection import cross_val_score
cv_nb = cross_val_score(nb_model, X, Y, cv=5, scoring='accuracy')

print("\nNaive Bayes Cross Validation Accuracy (5-Fold):")
print("Scores:", cv_nb)
print("Mean Accuracy: ", cv_nb.mean())
print("Standart Deviation: ", cv_nb.std())

Naive Bayes Cross Validation Accuracy (5-Fold):
Scores: [0.92105263 0.92105263 0.94736842 0.94736842 0.95575221]
Mean Accuracy: 0.9385188635305075
Standart Deviation: 0.014585994424363306
```

Gambar 2.12. Hasil menunjukkan bahwa tingkat akurasi Mean 0.93

KESIMPULAN

Proyek ini berhasil mengimplementasikan dan membandingkan kinerja algoritma Gaussian Naive Bayes (GNB) pada dua set data klasifikasi biner, yaitu prediksi kelangsungan hidup penumpang Titanic dan diagnosis Kanker Payudara Wisconsin. Proses implementasi mencakup langkah-langkah kritis seperti pra-pemrosesan data (penghapusan fitur non-informatif dan encoding), feature scaling, serta evaluasi model menggunakan Confusion Matrix dan 5-Fold Cross-Validation. Hasil Cross-Validation pada data Kanker Payudara menunjukkan performa model yang kuat dan andal dengan Akurasi Rata-rata 93.85% dan standar deviasi yang sangat rendah (0.0146). Visualisasi boxplot dari fitur-fitur utama, seperti radius_mean, mengonfirmasi bahwa terdapat pemisahan kelas yang jelas, yang menjadi kunci tingginya akurasi model GNB.

Meskipun model GNB memberikan hasil yang sangat baik dan stabil pada data Kanker Payudara, penting untuk dicatat bahwa akurasi 100% yang dilaporkan pada dataset Titanic adalah hasil yang tidak realistis dan kemungkinan besar berasal dari data leakage atau skema pengujian yang tidak valid pada file praktikum awal. Oleh karena itu, Akurasi Rata-rata 93.85% pada data Kanker Payudara, yang divalidasi dengan kuat melalui Cross-Validation dan analisis fitur, merupakan representasi yang lebih jujur dan meyakinkan dari kemampuan generalisasi model GNB. Secara keseluruhan, algoritma Naive Bayes terbukti menjadi solusi yang efisien dan efektif untuk tugas klasifikasi, menawarkan kinerja tinggi dengan kompleksitas komputasi yang rendah.

Referensi:

M Yasser H

Wine Quality Prediction - Classification Prediction

<https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>

<archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv>