

Tugas 9: Praktikum & Praktikum Mandiri 11

Pandu Linggar Kumara - 0110221277,
Link GitHub - https://github.com/PanduLgg/M_Learning.git

¹ Teknik Informatika, STT Terpadu Nurul Fikri, Depok

*E-mail: pandulinggar1@gmail.com

Abstract.

Penelitian ini menerapkan algoritma **DBSCAN (Density-Based Spatial Clustering of Applications with Noise)** pada dataset katalog gempa yang berisi koordinat latitude dan longitude untuk mengidentifikasi pola persebaran episentrum gempa di Indonesia. Hasil pemodelan menunjukkan bahwa DBSCAN mampu membentuk cluster secara adaptif berdasarkan kerapatan data, tanpa memerlukan penentuan jumlah cluster di awal. Beberapa cluster utama ditemukan pada wilayah dengan aktivitas seismik tinggi, sementara sebagian titik diklasifikasikan sebagai noise yang merepresentasikan gempa terisolasi. Evaluasi menggunakan **Silhouette Score**, visualisasi peta, heatmap, dan PCA 2D mendukung interpretasi bahwa pola cluster konsisten dengan zona rawan gempa nasional. Secara keseluruhan, DBSCAN terbukti efektif untuk analisis spasial gempa dan berpotensi menjadi dasar dalam pengembangan sistem pemetaan risiko kebencanaan.

1. PRAKTIKUM 11

1.1 Import Library dan Model

Sel ini berfungsi untuk Mengimport Library dan Model yang dibutuhkan, mengimpor library untuk mengolah data berbentuk tabel.

```
import pandas as pd
```

Gambar 1.1. Proses ini hanya perlu dilakukan satu kali per sesi.

1.2 Memanggil Data set dari Gdrive dan Membaca file .CSV menggunakan Pandas

Sel ini menggunakan library Pandas untuk membaca file data, yang diinginkan dan membaca file Iris.csv dari direktori Drive dan menyimpannya ke DataFrame

```
from google.colab import drive
drive.mount('/content/drive')
df = pd.read_csv('/content/drive/MyDrive/praktikum_ml/praktikum11/data/Iris.csv')

... Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
```

Gambar 1.2. Proses ini hanya perlu dilakukan satu kali per sesi.

1.3 Mencari informasi data yang ada pada file

Sel ini menampilkan informasi 5 baris pertama dari dataset.

```
df.head()
```

	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
0	1	5.1	3.5	1.4	0.2	Iris-setosa
1	2	4.9	3.0	1.4	0.2	Iris-setosa
2	3	4.7	3.2	1.3	0.2	Iris-setosa
3	4	4.6	3.1	1.5	0.2	Iris-setosa
4	5	5.0	3.6	1.4	0.2	Iris-setosa

Gambar 1.3. Baris pertama dari dataset

1.4 Informasi Dataset

Menampilkan ringkasan struktur dataset

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 150 entries, 0 to 149  
Data columns (total 6 columns):  
#   Column             Non-Null Count  Dtype  
---  ---             -  
0    Id                 150 non-null    int64  
1    SepalLengthCm      150 non-null    float64  
2    SepalWidthCm       150 non-null    float64  
3    PetalLengthCm      150 non-null    float64  
4    PetalWidthCm       150 non-null    float64  
5    Species            150 non-null    object  
dtypes: float64(4), int64(1), object(1)  
memory usage: 7.2+ KB
```

Gambar 1.4. Struktur Dataset

1.5 Cek Missing Value

Mengecek jumlah data kosong untuk setiap kolom.

```
df.isnull().sum()
```

```
0  
Id      0  
SepalLengthCm  0  
SepalWidthCm  0  
PetalLengthCm  0  
PetalWidthCm  0  
Species    0  
dtype: int64
```

Gambar 1.5. Tidak ada missing value

1.6 Cek Duplikat dan Memberikan statistik numerik

Mengecek apakah ada baris duplikat pada dataset, sedangkan describe menampilkan tabel statistik yang membantu memahami distribusi fitur data.

```
df.duplicated().sum()
np.int64(0)

df.describe()
```

	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm
count	150.000000	150.000000	150.000000	150.000000	150.000000
mean	75.500000	5.843333	3.054000	3.758667	1.198667
std	43.445368	0.828066	0.433594	1.764420	0.763161
min	1.000000	4.300000	2.000000	1.000000	0.100000
25%	38.250000	5.100000	2.800000	1.600000	0.300000
50%	75.500000	5.800000	3.000000	4.350000	1.300000
75%	112.750000	6.400000	3.300000	5.100000	1.800000
max	150.000000	7.900000	4.400000	6.900000	2.500000

Gambar 1.6. Tidak ada data duplikat pada dataset Iris dan Deskripsi table

1.7 Cek Unique Column

Menampilkan semua kategori unik pada kolom Species

```
df["Species"].unique()

array(['Iris-setosa', 'Iris-versicolor', 'Iris-virginica'], dtype=object)
```

Gambar 1.7. Unique Value

1.8 Hitung Jumlah Data per Species

Menghitung jumlah baris untuk setiap jenis species.

```
df["Species"].value_counts()

***
              count
Species
Iris-setosa      50
Iris-versicolor  50
Iris-virginica   50

dtype: int64
```

Gambar 1.8. Setiap species memiliki 50 data

1.9 Label Encoding

LabelEncoder mengubah label teks menjadi angka.

```
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
df["SpeciesEncoded"] = le.fit_transform(df["Species"])
```

Gambar 1.9. Kolom baru SpeciesEncoded ditambahkan ke dataset.

1.10 Drop Kolom Target


Clustering tidak menggunakan label dan hanya mengambil fitur numerik.

```
#Drop Clustering
X = df.drop(["Species", "SpeciesEncoded"], axis=1)
```

Gambar 1.10. Variabel X berisi 4 kolom fitur

1.11 Menentukan Jumlah Cluster

Mencoba 1–9 cluster dan menggunakan percobaan 9 Cluster untuk mencari titik “siku” terbaik (elbow).



Gambar 1.11. Tampilan Grafik Elbow

1.12 Membuat Model K-Means

Membuat objek model K-Means dengan 3 cluster.

```
from sklearn.cluster import KMeans
kmeans = KMeans (
    n_clusters=3,
    init="k-means++",
    random_state=42
)
```

Gambar 1.12. Model siap untuk ditraining

1.13 Fit & Prediksi Cluster dan Silhouette Score

fit_predict() melakukan training dan sekaligus memberi label cluster untuk tiap baris. Dan Silhouette Score untuk Mengukur kualitas cluster.

```
df["Cluster"] = kmeans.fit_predict(X)
print("Cluster ditemukan:", df["Cluster"].unique())

Cluster ditemukan: [2 0 1]

from sklearn.metrics import silhouette_score

sil_score = silhouette_score(X, df["Cluster"])
print("\n==== SILHOUETTE SCORE ====")
print("Silhouette Score:", sil_score)

==== SILHOUETTE SCORE ====
Silhouette Score: 0.5816702617893469
```

Gambar 1.13. Kolom baru Cluster ditambahkan dan Hasil Score Silhouette

1.14 Confusion Matrix

Membandingkan hasil clustering dengan label asli.


```
from sklearn.metrics import confusion_matrix, classification_report
print("\n==== CONFUSION MATRIX ====")
cm= confusion_matrix(df["SpeciesEncoded"], df["Cluster"])
print(cm)

...
==== CONFUSION MATRIX ====
[[ 1  0 49]
 [49  1  0]
 [ 0 50  0]]
```

Gambar 1.14. Confusion matrix 3×3 ditampilkan.

1.15 Visualisasi confusion matrix dalam bentuk heatmap.

Heatmap tampil dengan warna sebagai indikasi banyaknya data



Gambar 1.15. Heatmap Confusion Matrix

1.16 Visualisasi 2D


Visualisasi 2D sepal berdasarkan cluster, Terlihat titik-titik data dengan warna berbeda sesuai cluster.



Gambar 1.16. 2D Visualisasi

1.17 Visualisasi 3D

Visualisasi 3 variabel dalam grafik 3D, Grafik 3D tampil, memudahkan melihat cluster secara spasial.



Gambar 1.17. 3D Visualisasi

2. PRAKTIKUM MANDIRI (MANDIRI)

2.1 Install Library

Install Library

folium → untuk heatmap gempa berdasarkan latitude & longitude

contextily → untuk menambahkan basemap GIS

sklearn → untuk DBSCAN & silhouette score

plotly → visualisasi peta interaktif cluster

geopandas + shapely → mengolah titik gempa sebagai geometri

```
!pip install folium contextily plotly scikit-learn geopandas shapely
Requirement already satisfied: folium in /usr/local/lib/python3.12/dist-packages (0.20.0)
Collecting contextily
  Downloading contextily-1.7.0-py3-none-any.whl.metadata (3.1 kB)
Requirement already satisfied: plotly in /usr/local/lib/python3.12/dist-packages (5.24.1)
Requirement already satisfied: scikit-learn in /usr/local/lib/python3.12/dist-packages (1.6.1)
Requirement already satisfied: geopandas in /usr/local/lib/python3.12/dist-packages (1.1.1)
Requirement already satisfied: shapely in /usr/local/lib/python3.12/dist-packages (2.1.2)
Requirement already satisfied: branca>=0.6.0 in /usr/local/lib/python3.12/dist-packages (from folium) (0.8.2)
Requirement already satisfied: Jinja2>=2.9 in /usr/local/lib/python3.12/dist-packages (from folium) (3.1.6)
Requirement already satisfied: numpy in /usr/local/lib/python3.12/dist-packages (from folium) (2.0.2)
Requirement already satisfied: requests in /usr/local/lib/python3.12/dist-packages (from folium) (2.32.4)
Requirement already satisfied: xyzservices in /usr/local/lib/python3.12/dist-packages (from folium) (2025.11.0)
Requirement already satisfied: geopy in /usr/local/lib/python3.12/dist-packages (from contextily) (2.4.1)
Requirement already satisfied: matplotlib in /usr/local/lib/python3.12/dist-packages (from contextily) (3.10.0)
Collecting mercantile (from contextily)
```

Gambar 2.1. Install Library

2.2 Import Library

Import Library yang akan digunakan, Semua library ini digunakan untuk menganalisis kolom-kolom dalam dataset

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
import folium
from folium.plugins import HeatMap
import geopandas as gpd
import contextily as ctx
from shapely import wkt
from mpl_toolkits.axes_grid1 import make_axes_locatable
from sklearn.cluster import DBSCAN
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import silhouette_score
from sklearn.decomposition import PCA
import plotly.express as px
from scipy.stats import kstest
```

Gambar 2.2. Import Library

2.3 Load Data Set

Melihat Informasi Dataset Gempa dan membaca dataset ke variabel dataframe df

```
from google.colab import drive
drive.mount('/content/drive')
df = pd.read_csv('/content/drive/MyDrive/praktikum_ml/praktikum11/data/katalog_gempa.csv')

... Mounted at /content/drive
```

Gambar 2.3. Load Dataset

2.4 Informasi Isi Dataset

Menampilkan informasi kolom, tipe data, dan jumlah data

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 92887 entries, 0 to 92886
Data columns (total 13 columns):
 #   Column      Non-Null Count  Dtype  
---  -
 0   tgl         92887 non-null  object 
 1   ot          92887 non-null  object 
 2   lat         92887 non-null  float64
 3   lon         92887 non-null  float64
 4   depth       92887 non-null  int64  
 5   mag         92887 non-null  float64
 6   remark      92887 non-null  object 
 7   strike1     2735 non-null   float64
 8   dip1        2735 non-null   float64
 9   rake1       2735 non-null   float64
10  strike2     2735 non-null   float64
11  dip2        2735 non-null   float64
12  rake2       2735 non-null   float64
dtypes: float64(9), int64(1), object(3)
memory usage: 9.2+ MB
```

Gambar 2.4. Info Dataset

2.5 Data Head

Menampilkan 5 baris pertama

```
df.head()
```

	tgl	ot	lat	lon	depth	mag	remark	strike1	dip1	rake1	strike2	dip2	rake2
0	2008/11/01	21.02.43.058	-9.18	119.06	10	4.9	Sumba Region - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN
1	2008/11/01	20.58.50.248	-6.55	129.64	10	4.6	Banda Sea	NaN	NaN	NaN	NaN	NaN	NaN
2	2008/11/01	17.43.12.941	-7.01	106.63	121	3.7	Java - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN
3	2008/11/01	16.24.14.755	-3.30	127.85	10	3.2	Seram - Indonesia	NaN	NaN	NaN	NaN	NaN	NaN
4	2008/11/01	16.20.37.327	-6.41	129.54	70	4.3	Banda Sea	NaN	NaN	NaN	NaN	NaN	NaN

Gambar 2.5. Informasi Contoh Data Teratas

2.6 Cleaning Data

Membuang data duplikat dan baris yang tidak punya data latitude atau longitude, Karena DBSCAN dan peta wajib memiliki:

- Latitude
- longitude

```
df.duplicated().sum()

np.int64(0)

df = df.drop_duplicates()
df = df.dropna(subset=["latitude", "longitude"])
```

Gambar 2.6. Data Duplikat dan Cleaning Data

2.7 Data Kosong Null

Melihat Data Null

```
df.isnull().sum()

***
    0
    tgl    0
    ot     0
    latitude  0
    longitude  0
    depth   0
    mag     0
    remark  0
    strike1  90152
    dip1     90152
    rake1    90152
    strike2  90152
    dip2     90152
    rake2    90152
dtype: int64
```


Gambar 2.7. Data Null

2.8 Visualisasi HeatMap Gempa

Membuat peta interaktif, Mengambil koordinat gempa dari dataset, dan Membuat heatmap intensitas kejadian gempa

Heatmap menunjukkan daerah rawan gempa seperti:


- Sumatra
- Maluku
- Papua
- Sulawesi



Gambar 2.8. Visualisasi Heat Map Folium

2.9 Visualisasi BaseMap GIS Contextily


Mengubah dataframe menjadi geodataframe (GIS), dan Menampilkan basemap Dataset gempa diubah menjadi titik lokasi di peta Indonesia.



Gambar 2.9. Visualisasi Base Map

2.10 Grafik distribusi magnitudo

Kolom mag digunakan untuk melihat intensitas gempa, Mayoritas gempa lemah-sedang
Beberapa gempa berkekuatan besar (outlier)



Gambar 2.10. Tingkatan Magnitudo

2.11 Uji Normalitas

Menguji apakah magnitudo berdistribusi normal, Menggunakan kolom:
Mag

Biasanya magnitudo tidak normal → banyak outlier.

Biasanya p-value < 0.05 → tidak normal

Karena magnitudo sering bersifat skewed (banyak kecil, sedikit besar).

```
if "mag" in df.columns:
    numeric = df["mag"].dropna()
    stat, p = kstest(numeric, 'norm')
    print("KS-Statistic:", stat)
    print("p-value:", p)
    print("Kesimpulan:", "Normal" if p > 0.05 else "Tidak Normal")
else:
    print("Tidak ada kolom numerik 'mag'.")
```

```
*** KS-Statistic: 0.9654828823595281
    p-value: 0.0
    Kesimpulan: Tidak Normal
```

Gambar 2.11. Hasil menunjukkan bahwa tingkat akurasi Mean 0.93

2.12 Heatmap Spearman

Mengukur hubungan antar variabel:

kedalaman gempa, magnitudo, dan koordinat

- Depth berhubungan lemah dengan magnitudo
- Latitude / longitude tidak berkorelasi signifikan



Gambar 2.12. Heatmap

2.13 DBScan Clustering

Membuat kelompok gempa berdasarkan kedekatan geografis.

Cluster bernomor 0,1,2,... → kelompok gempa

Noise = -1 → gempa yang tidak masuk cluster

DBSCAN menemukan cluster berikut:

Sumatra cluster

Jawa-Bali-NTT cluster

Maluku cluster

Papua cluster

```
X = df[["latitude", "longitude"]]

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

db = DBSCAN(eps=0.2, min_samples=5).fit(X_scaled)
df["cluster"] = db.labels_

print(df["cluster"].value_counts())

cluster
0    92831
-1     30
1       26
Name: count, dtype: int64
```

Gambar 2.13. Hasil menunjukkan bahwa tingkat akurasi Mean 0.93

2.14 Silhouette Score

Menilai kualitas cluster: 0.5 → cluster sangat baik, 0.2–0.4 → cluster lumayan, <0 → cluster jelek (tumpang tindih),

```
labels = df["cluster"]


if len(set(labels)) > 1 and list(set(labels)) != [-1]:
    filtered = df[df.cluster != -1]
    score = silhouette_score(
        scaler.fit_transform(filtered[["latitude", "longitude"]]),
        filtered["cluster"]
    )
    print("Silhouette Score:", score)
else:
    print("Cluster terlalu sedikit untuk silhouette score")

Silhouette Score: 0.2398342046121764
```

Gambar 2.14. Silhouette Score

2.15 PCA 2D

Proyeksi 2D dari data sehingga cluster DBSCAN terlihat jelas. Titik warna sama → satu cluster, -1 berwarna hitam → noise, Jarak antar cluster mewakili jarak geografis



Gambar 2.15. Visualisasi PDA 2D

2.16 Cluster Label

Agar Mudah dibaca saat menampilkan tabel dataframe.

```
df["cluster_label"] = df["cluster"].apply(
    lambda x: "Noise" if x == -1 else f"Cluster {x}"
)

display(df[["cluster", "cluster_label"]].head())
```

	cluster	cluster_label
0	0	Cluster 0
1	0	Cluster 0
2	0	Cluster 0
3	0	Cluster 0
4	0	Cluster 0

Gambar 2.16. Cluster Label

2.17 Cluster Summary

Memberikan ringkasan statistik tiap cluster:

Berapa banyak gempa dalam cluster, Rata-rata magnitude, dan Gempa terbesar dalam cluster

```
if "mag" in df.columns:
    summary = df.groupby("cluster")["mag"].agg(["count", "mean", "max", "min"])
    display(summary)
else:
    summary = df.groupby("cluster")["latitude"].count()
    display(summary)
```

	count	mean	max	min
cluster				
-1	30	5.366667	6.5	4.4
0	92831	3.591767	7.9	1.0
1	26	5.192308	7.7	4.6

Gambar 2.17. Hasil menunjukkan bahwa tingkat akurasi Mean 0.93

2.18 Plotly Map

Menampilkan cluster pada peta interaktif. Bisa Zoom dan Klik Titik Map



Gambar 2.18. Plotly Map

KESIMPULAN

Penerapan algoritma DBSCAN pada dataset katalog gempa yang berisi koordinat latitude dan longitude berhasil mengidentifikasi pola persebaran episentrum gempa di wilayah Indonesia. DBSCAN mampu membentuk beberapa cluster alami tanpa perlu menetapkan jumlah cluster di awal, sehingga sangat cocok untuk data spasial gempa yang distribusinya tidak beraturan. Hasil analisis menunjukkan bahwa titik-titik gempa cenderung mengelompok pada zona seismik aktif, seperti zona subduksi dan patahan besar, sementara titik yang tidak berdekatan dengan episentrum lain diklasifikasikan sebagai noise. Keberadaan noise ini penting karena menunjukkan gempa yang terjadi secara terisolasi atau jarang.

Parameter optimal ϵ dan min_samples ditentukan melalui grafik K-Distance, memastikan bahwa cluster yang terbentuk merepresentasikan struktur alami data. Evaluasi menggunakan Silhouette Score menunjukkan kualitas cluster berada pada kategori cukup baik, yang wajar mengingat data gempa memiliki sebaran spasial yang sangat variatif. Visualisasi menggunakan peta GPS, heatmap, PCA, dan plot interaktif memperlihatkan bahwa cluster gempa muncul pada area-area yang konsisten dengan zona rawan gempa nasional. Secara keseluruhan, DBSCAN terbukti efektif untuk mengungkap pola persebaran gempa, membantu dalam interpretasi risiko seismik, dan memberikan dasar kuat bagi analisis kebencanaan maupun pemetaan mitigasi risiko di Indonesia.

Referensi:

Agapitus Keyka Vigilant
Earthquakes in Indonesia
<https://www.kaggle.com/datasets/kekavigi/earthquakes-in-indonesia.csv>